

OOB-Fehler

Random Forest liefert automatisch:

- OOB RMSE
- OOB R^2

Man testet verschiedene Kombinationen:

minsplit	minbucket	OOB R^2
10	3	0.58
20	5	0.63
30	10	0.67
50	15	0.62


→ beste Kombination:

```
minsplit = 30
minbucket = 10
```

Für eure Arbeit könnte man schreiben

Die Hyperparameter wurden anhand des Out-of-Bag-Fehlers optimiert. Die Mindestanzahl an Beobachtungen pro Split (minsplit) sowie die Mindestanzahl an Beobachtungen in den Endknoten (minbucket) wurden schrittweise variiert. Die finale Parametrisierung wurde so gewählt, dass ein möglichst hoher OOB- R^2 -Wert bei gleichzeitig geringer Modellkomplexität erreicht wurde. Zusätzlich wurde mit einem Signifikanzniveau von $p < 0.001$ (mincriterion = 0.999) gearbeitet, um statistisch nicht belastbare Splits zu vermeiden und Overfitting zu reduzieren. □

Das ist eine Begründung, wie sie in Bachelor-, Master- und Geoprojektarbeiten typischerweise akzeptiert wird.



hobley_rf_erklaerungbeispiel_repaired.pdf

PDF

kannst du mir genau ihr decision tree erklären? und wie lässt es sich mit meinem decision tree aus unserem projekt vergleichen und erklären?

Ja. Das Bild, das du hochgeladen hast, ist eigentlich ein sehr gutes Beispiel, um genau die Konzepte aus Hobileys Vorlesung zu erklären. Man kann praktisch jeden Begriff aus den Folien direkt an diesem Baum zeigen.

Aus Hobileys Definition entsteht ein Entscheidungsbaum durch **recursive partitioning**: Der Datensatz wird immer wieder so aufgeteilt, dass die resultierenden Gruppen möglichst homogen werden (geringe Varianz bzw. geringer RMSE).

hobley_rf_erklaerungbeispiel_re...

1. Root Node identifizieren

Ganz oben steht:

```
rain_mmsqm_mean_1995_2024 <= 783.425
squared_error = 0.199
samples = 2411
value = 3.126
```

Das ist der **Root Node**.

Hobley beschreibt den Root Node als den ersten Knoten, der alle Beobachtungen enthält.

hobley_rf_erklaerungbeispiel_re...

Interpretation

Der Algorithmus hat alle Variablen getestet:

- Niederschlag
- Temperatur
- Höhe
- Klima
- Landnutzung

und festgestellt:

Der Split bei 783.425 mm Niederschlag reduziert die Varianz des SHI stärker als jeder andere mögliche erste Split.

Deshalb wurde Niederschlag zur Wurzel des Baumes.

2. Warum genau 783.425 mm?

Der Algorithmus hat intern hunderte Schwellenwerte geprüft:

```
Rain < 600
Rain < 650
```

```
Rain < 700
Rain < 750
Rain < 783.425
Rain < 800
Rain < 850
...
```

Für jeden Split wurde berechnet:

$$MSE_{nach\ Split}$$

Der Wert 783.425 mm ergab die größte Varianzreduktion.

Genau das beschreibt Hobley:

"maximum group purity (minimum entropy, RMSE)"

hobley_rf_erklaerungbeispiel_re...

3. Linker Branch

Wenn

```
Rain ≤ 783.425 mm
```

dann gelangen 1811 Beobachtungen in den linken Ast:

```
land_cover_Cropland ≤ 0.5
samples = 1811
value = 3.031
```



Jetzt sucht der Algorithmus innerhalb dieser Teilgruppe erneut den besten Split.

Von allen Variablen war nun:

```
Cropland ja/nein
```

am informativsten.

4. Rechter Branch

Wenn

```
Rain > 783.425 mm
```

landet man rechts:

```
temp_c_mean_1995_2024 ≤ 14.055
samples = 600
value = 3.414
```

Hier ist Niederschlag bereits erklärt.

Jetzt liefert Temperatur die stärkste weitere Varianzreduktion.

Der Baum sagt also:

In niederschlagsreichen Gebieten wird der SHI hauptsächlich durch Temperatur differenziert.

5. Was bedeutet squared_error?

Beispiel:

```
squared_error = 0.199
```

Das entspricht der Varianz des SHI innerhalb dieses Knotens.

Je kleiner:

```
squared_error
```

desto homogener die Gruppe.

Genau das möchte der Baum erreichen.

6. Was bedeutet value?

Beispiel:

```
value = 3.126
```

Das ist der mittlere SHI aller Beobachtungen in diesem Knoten. □

Also:

$$\bar{y} = 3.126$$

7. Was bedeutet samples?

```
samples = 2411
```

2411 Punkte befinden sich im Root Node.

Nach jedem Split werden die Beobachtungen aufgeteilt.

Beispiel:

```
2411
↓
1811 + 600
```

8. Warum erscheinen Klima-Klassen?

Später sieht man:

```
climate_name_Cfb
```

oder

```
climate_name_Dfb
```

Das sind One-Hot-kodierte Kategorien.

Beispiel:

```
climate_name_Cfb <= 0.5
```

bedeutet:

```
Ist NICHT Cfb-Klima
```

```
climate_name_Cfb > 0.5
```

bedeutet:

```
Ist Cfb-Klima
```

Der Baum erkennt also:

Bei ähnlichem Niederschlag und ähnlicher Landnutzung spielt die Klimazone eine zusätzliche Rolle.

9. Was sagt der Baum fachlich?



Wenn man den Baum liest:

Wichtigster Einfluss

Root Node:

```
Niederschlag
```

⇒ stärkster Einfluss auf SHI

Zweitwichtig

Danach:

```
Cropland  
Temperatur
```

Drittwichtig

Später:

```
Höhe  
Klimazone  
Woodland
```

Fallow land Forestry

Man könnte also schreiben:

Der repräsentative Entscheidungsbaum zeigt, dass der mittlere Jahresniederschlag den stärksten Einfluss auf die SHI-Ausprägung besitzt. Innerhalb niederschlagsärmerer Regionen wird der SHI insbesondere durch landwirtschaftliche Nutzungstypen differenziert, während in niederschlagsreicheren Regionen die Temperatur den wichtigsten zusätzlichen Einflussfaktor darstellt.

Vergleich mit eurem Projekt

Euer SHI-Projekt basiert laut Hobley auf:

$$SHI = f(Klima, Topographie, Landnutzung, Geologie)$$

hobley_rf_erklaerungbeispiel_re...

Wenn euer Baum ähnlich aussieht, könnt ihr dieselbe Logik anwenden:

Root Node

Frage:

Welche Variable steht ganz oben?



Beispiele:

height

→ Topographie dominiert

temperature

→ Klima dominiert

land use

→ Nutzung dominiert

Erste Tochterknoten

Frage:

Welche Variable erscheint direkt danach?

Das zeigt:

Welche Faktoren innerhalb der Hauptgruppe zusätzlich wichtig werden.

Tiefe Knoten

Die unteren Knoten zeigen Interaktionen.

Beispiel:

```
Regen
→ Temperatur
→ Höhe
```

bedeutet:

Der Einfluss der Höhe hängt vom Niederschlag und von der Temperatur ab.

Das ist genau die Art von Interaktion, die Hopley mit Machine Learning untersuchen möchte.

hobley_rf_erklaerungbeispiel_re...

Für die Diskussion in eurer Arbeit

Du könntest schreiben:

Der Root Node des repräsentativen Entscheidungsbaums basiert auf dem mittleren Jahresniederschlag, was darauf hindeutet, dass dieser Faktor den größten Beitrag zur Verringerung der SHI-Varianz leistet. Die nachfolgenden Splits zeigen, dass Landnutzung, Temperatur und Klimazone die SHI-Werte innerhalb der durch den Niederschlag definierten Gruppen weiter differenzieren. Der Baum verdeutlicht damit die hierarchische Bedeutung der Einflussfaktoren sowie potenzielle Wechselwirkungen zwischen Klima-, Topographie- und Landnutzungsvariablen. □

Wenn du mir den **Entscheidungsbaum aus eurem eigenen Modell** (oder den Export aus Python/R) zeigst, kann ich ihn anschließend Knoten für Knoten genauso analysieren und direkt mit Hopleys Theorie verknüpfen.

was meinst du hier mit am informativsten? Von allen Variablen war nun:

Cropland ja/nein

am informativsten. - welche teilung die stärkste varianzreduktion liefert? 8. kannst du mir das nochmal erklären was bedeutet genau $\text{climate_name_Cfb} \leq 0.5$ und $\text{climate_name_Cfb} > 0.5$ und wo steht es im decision tree? außerdem hat nicht eigentlich cropland die meiste bzw beste auswirkung auf den shi index? ich mein bewirtschaftete flächen/böden sind doch eigentlich direkt gesunde böden oder? oder bei Forest? Und kannst du mir den decision tree noch mal genau so entwickelt nur mit richtigen Namen, bezeichnung und erklärung kryptischen namensbezeichnungen und zahlen. Also was sagen alle verzweigungen genau und wie lassen sie sich erklären und bewerten.

Sehr gute Fragen. Genau an diesen Stellen passieren häufig Fehlinterpretationen von Entscheidungsbäumen.

1. Was bedeutet „Cropland ist am informativsten“?

Mit **informativ** meine ich nicht:

"Cropland ist die wichtigste Variable für den SHI."

sondern:

"Innerhalb dieser Teilgruppe liefert Cropland den Split mit der größten zusätzlichen Varianzreduktion."

Das ist ein großer Unterschied.

Der Baum arbeitet immer lokal.

Schritt 1

Zuerst wurde geteilt nach:

Niederschlag $\leq$ 783 mm

Danach bleiben nur noch die 1811 Punkte links übrig.

Jetzt fragt der Baum:

Bei diesen 1811 Punkten: Welche Variable trennt die SHI-Werte am besten?



Er testet erneut:

- Temperatur
- Höhe
- Cropland
- Wald
- Klimazone
- usw.

und findet:

Cropland $\leq$ 0.5

liefert die größte weitere Verringerung des Fehlers.

Deshalb wird Cropland gewählt.

Das bedeutet nicht automatisch:

Cropland ist global die wichtigste Variable.

Dafür bräuchte man die **Feature Importance** des gesamten Random Forest.

2. Wo steht das im Baum?

Direkt links unter dem Root Node:

```
Rain ≤ 783 mm
├── Cropland ≤ 0.5
```

Das ist die zweite Ebene.

3. Was bedeutet Cropland ≤ 0.5?

Hier kommt die One-Hot-Kodierung ins Spiel.

Ursprünglich gab es wahrscheinlich:

```
Land Cover:
- Cropland
- Forest
- Grassland
- Woodland
- Urban
...
```

Machine Learning kann mit Text nicht rechnen.

Deshalb wird:

Cropland



ZU:

Fläche	land_cover_Cropland
Cropland	1
Forest	0
Woodland	0
Grassland	0

Dann bedeutet:

land_cover_Cropland ≤ 0.5

=

kein Cropland

und

land_cover_Cropland > 0.5

=

Cropland

4. Bedeutet Cropland automatisch gesunde Böden?

Nein.

Das wäre eine fachliche Fehlinterpretation.

Der Baum sagt lediglich:

Die SHI-Werte unterscheiden sich zwischen Cropland und Nicht-Cropland.

Aber:

Der Baum sagt nicht:

- Cropland ist besser
- Cropland ist schlechter

sondern nur:

- unterschiedlich

Man müsste die Mittelwerte vergleichen.

Hier steht:



value = 3.031

vor dem Split.

Danach entstehen zwei neue Gruppen.

Erst deren Werte würden zeigen:

- steigt SHI?
- sinkt SHI?

In der Bodenkunde kann beides vorkommen.

Cropland kann positiv sein

z.B.

- gute Bewirtschaftung
- Fruchtfolge
- organische Düngung

Cropland kann negativ sein

z.B.

- Verdichtung
- Erosion
- Monokultur
- Humusverlust

Deshalb sollte man niemals sagen:

Cropland = gesunder Boden.

5. Ist Forest dann besser?

Auch nicht automatisch.

Viele Leute denken:

Wald = gesund

Das stimmt nicht immer.

Beispiele:

Wald positiv



- hoher Humusgehalt
- hohe biologische Aktivität

Wald negativ

- saure Böden
- Nährstoffmangel
- flachgründige Böden

Der Baum bewertet nicht:

gut oder schlecht

sondern:

statistisch unterschiedlich

6. Was bedeutet `climate_name_Cfb ≤ 0.5`?

Das ist wieder One-Hot-Encoding.

Cfb

Nach Köppen-Geiger:

Cfb
=
temperiertes Klima
ohne Trockenzeit
warmer Sommer

z.B.

- Deutschland
- Schweiz
- Österreich
- Nordfrankreich

Im Datensatz:

Klima	climate_name_Cfb
Cfb	1
Dfb	0
Csa	0



Dann bedeutet:

`climate_name_Cfb ≤ 0.5`

=

nicht Cfb

und

`climate_name_Cfb > 0.5`

=

Cfb-Klima

7. Wo steht das im Baum?

Links mittig:

Climate Cfb
Temperate, no dry season, warm summer
≤ 0.5

Der Baum fragt dort:

Haben Standorte im Cfb-Klima andere SHI-Werte als Standorte in anderen Klimazonen?

8. Was bedeutet climate_name_Dfb?

```
Dfb
=
kaltgemäßigtes Klima
keine Trockenzeit
warmer Sommer
```

z.B.

- Polen
- Baltikum
- Südkanada

Split:

```
climate_name_Dfb ≤ 0.5
```

=

nicht Dfb



```
climate_name_Dfb > 0.5
```

=

Dfb

9. Was sagt der ganze Baum fachlich?

Wenn man die Variablen in Klartext übersetzt:

Root Node

```
Jahresniederschlag ≤ 783 mm?
```

Interpretation:

Niederschlag ist der wichtigste Einflussfaktor.

Niederschlagsarme Gebiete

Ist die Fläche Ackerland?

Interpretation:

Bei wenig Niederschlag wird die Landnutzung wichtig.

Nicht-Ackerland

Ist die Fläche Brachland?

Interpretation:

Bei trockenen Gebieten und Nicht-Ackerland unterscheiden sich SHI-Werte zwischen Brachflächen und anderen Nutzungen.

Ackerland

Liegt ein Cfb-Klima vor?

Interpretation:

Innerhalb von Ackerflächen beeinflusst zusätzlich die Klimazone den SHI.

Danach



Höhe $\leq$ 270 m?

Interpretation:

In dieser Klimazone wird nun die Topographie relevant.

Niederschlagsreiche Gebiete

Temperatur $\leq$ 14 °C?

Interpretation:

Wenn ausreichend Wasser vorhanden ist, wird Temperatur zum dominierenden Faktor.

Danach

Woodland?

Interpretation:

Die Landbedeckung beeinflusst den SHI zusätzlich.

Danach

Mediterranes Klima?

(Csa)

Interpretation:

Die Klimazone erklärt weitere Unterschiede.

Was würde Hobley wahrscheinlich daraus schließen?

Der Baum deutet auf eine Hierarchie hin:

```
1. Niederschlag
↓
2. Temperatur / Landnutzung
↓
3. Klimazone
↓
4. Höhe
```

Das passt sehr gut zu Bodengesundheitsstudien:

- Klima bestimmt Wasserverfügbarkeit
- Landnutzung beeinflusst Bodenprozesse
- Topographie verändert Mikroklima und Erosion
- Klimazonen beeinflussen langfristige Bodenentwicklung



Genau deshalb ist der Baum wissenschaftlich interessant: Er zeigt nicht nur **welche Variablen wichtig sind**, sondern auch **in welcher Reihenfolge und unter welchen Bedingungen sie wichtig werden**. Das ist der eigentliche Mehrwert von Entscheidungsbäumen und Random Forests in eurem GEO-Projekt.

Bei diesen 1811 Punkten: Welche Variable trennt die SHI-Werte am besten? : wie werden diese punkte im zweig getreent? wie geht man da vor und wieso? und wie lässt sich das mit einer grafik/diagramm/streuediagramm/boxplot oder sonstiges am besten erklären? Und wie lassen sich am ende die final outcome n observation erklären? und wurde dort schon data mining Bias-variance tradeoff gemacht? falls nein wie müsste man vorgehen? Also du sagt erstmal cropland ist 1 und wenn da cropland > 0,5 ist dann ist es cropland. Müsste es denn nicht cropland = 1 sein? oder müsste es nicht einfach ja oder nein sein? Und nochmal der baum versucht am die aus all den verzweigungen die entscheidung zu sammeln mit den faktoren die am ende immer zu einem guten index führen? weil ich sehe ja bei allen am ende einen index von mindestens 2,7

Du stellst genau die Fragen, die man für die Methodik und Diskussion einer wissenschaftlichen Arbeit verstehen muss. Tatsächlich gibt es hier einen wichtigen Denkfehler, den viele am Anfang haben:

Der Baum sucht **nicht nach "guten Böden"**.

Der Baum sucht nach **Unterschieden im SHI**.

1. Wie werden die 1811 Punkte nach Cropland getrennt?

Nehmen wir den linken Ast:

Niederschlag ≤ 783 mm
samples = 1811

Jetzt liegen dort 1811 Standorte.

Der Baum betrachtet beispielsweise die Variable:

land_cover_Cropland

Die Werte sind intern:

Standort	Cropland
A	1
B	1
C	0
D	0
E	1

Dann testet er:

Cropland ≤ 0.5



Das trennt automatisch:

Gruppe 1

Cropland = 0

kein Ackerland

Gruppe 2

Cropland = 1

Ackerland

Warum schreibt sklearn dann 0.5?

Weil Entscheidungsbäume immer mit Ungleichungen arbeiten:

$x \leq \text{Schwellenwert}$

Für eine binäre Variable (0 oder 1) ist

≤ 0.5

genau dasselbe wie

$= 0$

und

> 0.5

genau dasselbe wie

$= 1$

Also:

Cropland ≤ 0.5

=

Kein Cropland

2. Warum wird genau Cropland gewählt?

Der Baum berechnet für jede Variable:



Wie stark sinkt die SHI-Varianz nach dem Split?

Beispiel:

vor Split:

SHI
2.0
2.5
3.0
4.0
4.5

große Streuung

nach Cropland-Split:

Nicht-Cropland

SHI
2.0
2.1

SHI
2.2

Cropland

SHI
4.0
4.1
4.2

Jetzt sind beide Gruppen viel homogener.

Die Varianz sinkt.


Genau deshalb wird gesplittet.

hobley_rf_erklaerungbeispiel_re...

3. Wie könnte man das grafisch erklären?


Ein Boxplot wäre wahrscheinlich die beste Darstellung.

Vor dem Split



große Streuung

Nach Cropland-Split



kleine Streuung innerhalb der Gruppen

großer Unterschied zwischen den Gruppen

Genau das meint Hobley mit:

maximale Gruppenreinheit (group purity)

hobley_rf_erklaerungbeispiel_re...

4. Was bedeuten die finalen Endknoten?

Nehmen wir einen hypothetischen Pfad:

```
Rain > 783
↓
Temp < 14
↓
Woodland
↓
Leaf
```

Dann steht dort beispielsweise:

```
samples = 45
value = 3.52
```

Interpretation:

Diese 45 Standorte haben:

- Niederschlag > 783 mm
- Temperatur < 14 °C
- Woodland



Der durchschnittliche SHI dieser Gruppe beträgt:

3.52

5. Ist das Data Mining?

Ja.

Genau das nennt Hobley:

Untersuchung komplexer Beziehungen durch Modellierung und Interpretation.

hobley_rf_erklaerungbeispiel_re...

Der eigentliche Data-Mining-Teil beginnt nach dem Training:

- Welche Variablen sind wichtig?
- Welche Kombinationen treten auf?
- Welche Interaktionen existieren?

6. Wurde hier schon Bias-Variance Tradeoff gemacht?

Wahrscheinlich nicht.

Dein Baum zeigt nur:

```
max_depth = 3
```

Das ist eher eine Visualisierung.

Der Bias-Variance Tradeoff wird normalerweise über Hyperparameter untersucht. Hobbey erwähnt dazu die Optimierung von Modellparametern.

hobbey_rf_erklaerungbeispiel_re...

Man würde mehrere Modelle vergleichen:

max_depth	OOB-R ²
2	0.50
4	0.62
8	0.71
20	0.69

Dann sieht man:

- zu klein → Underfitting (hoher Bias)
- zu groß → Overfitting (hohe Varianz)

Optimum irgendwo dazwischen.



7. Sammelt der Baum Faktoren, die zu einem guten SHI führen?

Nicht ganz.

Das ist der wichtigste Punkt.

Der Baum fragt nicht:

Wie bekomme ich den höchsten SHI?

sondern:

Wie kann ich die Beobachtungen möglichst gut nach ihrem SHI unterscheiden?

Das Ziel ist Vorhersage.

Beispiel:

SHI-Werte:

```
2.0
2.1
2.2
3.5
3.6
3.7
```

Der Baum erkennt:

```
Cropland trennt diese Gruppen perfekt.
```

Dann splittet er.

8. Warum liegen alle Werte zwischen 2.7 und 3.5?

Weil dein Datensatz vermutlich einen relativ engen SHI-Bereich hat.

Der Baum kann nichts erfinden.

Wenn die Daten ungefähr so aussehen:

```
Minimum = 2.5
Maximum = 3.8
```

dann werden die Endknoten natürlich nur Werte in diesem Bereich haben.

9. Kann man daraus trotzdem ableiten, was „gut“ für den SHI ist?

Ja, aber vorsichtig.

Wenn ein Pfad endet bei:

```
Rain > 783
Temp < 14
Woodland
SHI = 3.52
```



und ein anderer bei:

```
Rain < 783
Cropland
Cfb
Height < 270
SHI = 2.81
```

dann kann man sagen:

Die Kombination aus hohem Niederschlag, niedriger Temperatur und Woodland ist in diesem Datensatz mit höheren SHI-Werten verbunden als die Kombination aus geringem Niederschlag, Cropland und Cfb-Klima.

Aber:

Das bedeutet nicht automatisch Ursache und Wirkung.

Der Baum zeigt statistische Zusammenhänge, keine kausalen Beweise.

Für eure Diskussion ist genau dieser Unterschied wichtig. Der Random Forest identifiziert Bedingungen, unter denen höhere oder niedrigere SHI-Werte auftreten, und ordnet die Einflussfaktoren nach ihrer

Fähigkeit, Unterschiede im SHI zu erklären. Das ist etwas anderes als eine direkte Aussage darüber, welche Landnutzung "gute" oder "schlechte" Böden verursacht.

Für eure Diskussion ist genau dieser Unterschied wichtig. Der Random Forest identifiziert Bedingungen, unter denen höhere oder niedrigere SHI-Werte auftreten, und ordnet die Einflussfaktoren nach ihrer Fähigkeit, Unterschiede im SHI zu erklären. Das ist etwas anderes als eine direkte Aussage darüber, welche Landnutzung "gute" oder "schlechte" Böden verursacht.- aber wozu ist das model dann notwendig? wir wollten ja mit unserer forschungsfrage herausfinden Wie beeinflussen Landnutzung (land use Daten), Klima (Wetterdaten), Topographie (Relief) und Ausgangsmaterial ein Set komplementärer Bodengesundheits-Indikatoren (SHI abgeändert, aus dem Datensatz Bodenzustandserhebung, Thuenen) in Deutschland (, und welche Wechselwirkungen zwischen diesen Einflussfaktoren prägen die Bodengesundheit am stärksten)?

Das Modell ist genau deshalb notwendig. Eure Forschungsfrage ist nicht: „Ist Cropland gut oder schlecht?“, sondern:

Eure eigentliche Forschungsfrage

Wie beeinflussen Landnutzung, Klima, Topographie und Ausgangsmaterial den SHI in Deutschland, und welche Wechselwirkungen zwischen diesen Faktoren sind besonders wichtig?

Das ist eine multivariate und wahrscheinlich nichtlineare Fragestellung. Genau dafür ist ein Random Forest sinnvoll. ▣

Was das Modell leistet



1. Mehrere Einflussfaktoren gleichzeitig betrachten

Ihr habt nicht nur eine Variable, sondern viele:

- Landnutzung
- Klima
- Topographie
- Ausgangsmaterial / Geologie
- möglicherweise weitere Boden- oder Standortvariablen

Diese Faktoren wirken gleichzeitig und beeinflussen sich gegenseitig.
Ein einfacher Vergleich wie:

„Cropland vs. Forest“

ignoriert, dass Cropland oft in anderen Klimazonen, Höhenlagen oder geologischen Regionen vorkommt als Wald.

Der Random Forest kann diese Faktoren gemeinsam berücksichtigen.



2. Wechselwirkungen erkennen

Das ist wahrscheinlich der wichtigste Punkt für eure Arbeit.

Beispiel:

Der Effekt von Cropland auf SHI kann im trockenen Klima anders sein als im feuchten Klima.
Oder der Einfluss der Höhe kann sich zwischen verschiedenen Klimazonen unterscheiden.

Ein Entscheidungsbaum bildet genau solche Interaktionen ab:

Das bedeutet:

Nicht „Wald verursacht SHI = 3.5“, sondern:

Unter den Bedingungen „feucht“ + „kühl“ + „Woodland“ treten im Datensatz höhere SHI-Werte auf.

Das ist eine Interaktion zwischen Klima und Landnutzung.



3. Relative Bedeutung der Faktoren bestimmen

Random Forest liefert eine Feature Importance.

Damit könnt ihr quantitativ beantworten:

Welche Faktoren erklären den SHI am stärksten?

Ist Klima wichtiger als Landnutzung?

Ist Topographie nur sekundär relevant?



Das ist viel stärker als eine rein qualitative Aussage.

Warum das Modell keine Kausalität beweist

Hier liegt der entscheidende Unterschied:

Das Modell zeigt	Das Modell zeigt nicht
welche Variablen mit SHI zusammenhängen	dass eine Variable SHI verursacht
welche Kombinationen häufig mit hohen/niedrigen SHI auftreten	dass die beobachtete Beziehung kausal ist
welche Interaktionen statistisch relevant sind	dass alle Störfaktoren ausgeschlossen wurden

In einer Beobachtungsstudie ist das normal. Trotzdem sind solche Modelle wissenschaftlich sehr wertvoll, weil sie komplexe Muster sichtbar machen.

Wie ihr die Forschungsfrage beantworten könnt

Mit eurem Modell könnt ihr beispielsweise schreiben:

Warum ein Random Forest besser passt als ein einfaches lineares Modell

Fragestellung	Lineare Regression	Random Forest
Viele Einflussfaktoren gleichzeitig	teilweise	gut geeignet
Nichtlineare Beziehungen	schlecht	gut
Komplexe Interaktionen	nur explizit modelliert	automatisch erkannt
Robustheit gegenüber Ausreißern	geringer	höher
Interpretierbarkeit einzelner Splits	mittel	hoch (bei Einzelbaumdarstellung)

Deshalb ist das Modell für eure Forschungsfrage sinnvoll: Es dient nicht nur der Vorhersage des SHI, sondern vor allem der Exploration und Quantifizierung komplexer Zusammenhänge und Wechselwirkungen zwischen Klima, Landnutzung, Topographie und Ausgangsmaterial.



Kurz gesagt

Der Baum sucht nicht „die beste Landnutzung“. Er sucht die Aufteilungen der Daten, die Unterschiede im SHI am besten erklären. Genau daraus könnt ihr anschließend ableiten, welche Faktoren und Kombinationen mit höheren oder niedrigeren SHI-Werten verbunden sind.

2/2

ok da wir das jz haben möchten wir das evtl auf einer interaktiven Karte visualisieren mit ArcGIS Pro oder auch in ArcGIS Portal mit einer Web App. Was macht da Sinn, eine Potenzialanalyse oder irgendeine Analyse Werkzeug/Widget bauen um schnelle Visualisierungen von Ereignissen/Prognosen darzustellen? oder wie kann man die Bedeutung, die wir aus unserem Modell gewonnen haben am besten dort darstellen? □

Für eure Forschungsfrage würde ich **nicht** als Hauptprodukt eine klassische Potenzialanalyse bauen.

Eine Potenzialanalyse beantwortet typischerweise:

"Wo könnte etwas passieren?"

Eure Arbeit beantwortet eher:

"Welche Faktoren prägen die Bodengesundheit und wie unterscheiden sich diese Zusammenhänge räumlich?"

Das ist ein anderer Fokus.

Was ich für ArcGIS Pro / ArcGIS Online empfehlen würde

Variante 1 (am stärksten): SHI-Erklärungsatlas

Eine interaktive Karte, die zeigt:

- SHI-Wert
- wichtigste Einflussfaktoren
- Unsicherheit
- regionale Unterschiede

Layer 1

SHI Deutschland

Farbskala:

```
rot = niedriger SHI
gelb = mittel
grün = hoher SHI
```

Layer 2

Dominanter Einflussfaktor

Jeder Punkt bekommt:

```
Klima
Landnutzung
Topographie
Geologie
```

als wichtigste Variable.



Dann Karte:

```
blau = Klima
grün = Landnutzung
braun = Geologie
orange = Topographie
```

Damit beantwortet ihr direkt:

Welche Faktoren dominieren wo?

Layer 3

Modellunsicherheit

z.B.

```
OOB-RMSE
Prediction Interval
Standard Deviation der Bäume
```

Farbskala:

```
hell = sicher
dunkel = unsicher
```

Das wirkt sehr wissenschaftlich.

Variante 2: Explainable AI Web App

Das wäre mein Favorit.

ArcGIS Experience Builder oder Dashboards.

User klickt auf einen Punkt.

Popup:

Standort XY
Vorhergesagter SHI:
3.52

darunter:

Wichtigste Einflussfaktoren:

1. Niederschlag
42 %

2. Temperatur
28 %

3. Waldanteil
15 %

4. Höhe
10 %

5. Geologie
5 %



Das entspricht einer lokalen Feature Importance.

Extrem spannend für Betreuer und Prüfende.

Variante 3: Interaktionsanalyse

Eigentlich exakt eure Forschungsfrage.

Ihr untersucht Wechselwirkungen.

Dann könnte die Karte zeigen:

Klimadominierte Regionen

z.B.

Norddeutschland

Landnutzungsdominierte Regionen

z.B.

Ackerbauregionen

Topographiedominierte Regionen

z.B.

Mittelgebirge

Geologiedominierte Regionen

z.B.

bestimmte Ausgangsgesteine

Dann visualisiert ihr:

Nicht überall wirken dieselben Faktoren gleich stark.

Das ist wissenschaftlich sehr wertvoll.

Was man als Widget bauen könnte



Widget 1

"Was beeinflusst SHI hier?"

Klick auf Karte.

Ausgabe:

SHI = 3.41

Einfluss:

Niederschlag +++
Temperatur ++
Landnutzung +
Geologie +

Widget 2

Szenario-Analyse

Schieberegler:

+2°C Temperatur

oder

Landnutzung:
Cropland → Forest

Dann:

neuer prognostizierter SHI

anzeigen.

Das wäre fast schon ein kleiner digitaler Zwilling.

Was ich NICHT machen würde

Nur den Decision Tree darstellen.

Das interessiert euch methodisch.

Für Nutzer ist so etwas:

```
Rain > 783
→ Temp < 14
→ Woodland
```

schwer verständlich.

Das gehört in die Arbeit.

Nicht als Hauptkarte.

Wenn ich eure Arbeit als StoryMap aufbauen müsste

1. Forschungsfrage
2. Datengrundlagen
3. SHI-Karte Deutschland
4. Random-Forest-Modell
5. Feature Importance

z.B.:

Beispielhafte relative Bedeutung der Einflussfaktoren

Veranschaulichung der Random-Forest-Feature-Importance.

6. Interaktionsanalyse

7. Regionale Unterschiede

temperatur

8. Unsicherheiten

9. Szenario 100
ndnutzung

Für eine GEO-Projektarbeit wäre eine Kombination aus **StoryMap + Experience Builder** wahrscheinlich die überzeugendste Lösung, weil ihr damit nicht nur die Vorhersage zeigt, sondern die eigentliche wissenschaftliche Erkenntnis.

Welche Faktoren die Bodengesundheit wo und unter welchen Bedingungen am stärksten prägen.

0%

9%

18%

27%

36%

